

SK네트웍스 Family AI 캠프 12회차

데이터 분석과 머신러닝, 딥러닝 프로젝트 평가

□ 개요

- 프로젝트 명 : 가입 고객 이탈 예측
- 평가 산출물 : 인공지능 데이터 전처리 결과서, 인공지능 모델 학습 결과서, 학습된 인공지능 모델
- 깃허브 주소 : <https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN20-2nd-5TEAM>
- 평가 일시 : 2025-11-05
- 평가 대상 : 5팀(김태빈,오학성,조준상,박다정,황수현,이성현)
- 평가자 : 강사 이규영, 재직자 멘토

□ 평가 기준

산출물	평가 요소	배점	점수
인공지능 데이터 전처리 결과서	데이터 탐색 및 전처리 적절성 (12점): 데이터셋 로드 및 탐색적 데이터 분석(EDA)을 통해 데이터의 특성을 파악하고, 결측치 및 이상치를 식별하고 처리한 과정이 적절한지 평가. 결측치 및 이상치 처리 (8점): 결측치, 이상치 등의 문제를 효과적으로 처리했는지, 그 방법이 데이터에 적합한지 평가. 데이터 정제 및 변환 (7점): 데이터 정제 및 변환 작업(예: 스케일링, 인코딩, 표준화 등)이 잘 이루어졌는지 평가. 전처리 과정의 효율성 및 설명 (3점): 전처리 과정에서 데이터 변환 및 정제 방법에 대한 설명이 명확하고, 효율적으로 처리되었는지 평가.	30	30

인공지능 모델 학습 결과서	모델 선택 및 설계 (15점): 문제에 적합한 모델을 선택하고 설계한 방식이 합리적인지 평가. (예: SVM, 결정트리, 랜덤포레스트 등) 모델 학습 및 튜닝 (10점): 모델 학습 과정에서 하이퍼파라미터 튜닝 및 훈련 데이터에 대한 학습이 잘 이루어졌는지 평가. 성능 평가 및 비교 (10점): 모델의 성능을 평가하고, 여러 모델 간 성능 비교가 잘 이루어졌는지 (정확도, F1-score, 혼동 행렬 등) 평가. 학습 과정 및 분석 (5점): 학습 과정에서 발생한 문제와 해결 방법을 분석한 내용이 충실한지 평가.	40	40
학습된 인공지능 모델	모델 검증 및 평가 (12점): 학습된 모델의 검증 및 테스트 데이터셋을 활용하여 성능 평가가 잘 이루어졌는지, 모델의 일반화 성능이 잘 유지되었는지 평가. 모델 개선 및 최적화 (10점): 모델 성능을 향상시키기 위한 최적화 작업(하이퍼파라미터 튜닝, 앙상블 기법 등)을 잘 수행했는지 평가. 모델 설명 및 해석 (5점): 모델의 동작 원리와 결과에 대해 명확히 설명하고, 모델이 해결하고자 하는 문제와의 관계를 잘 해석했는지 평가. 실제 적용 가능성 및 확장성 (3점): 모델이 실제 문제에 얼마나 적용 가능한지, 새로운 데이터에 대해 확장 가능한지를 평가.	30	30
		100	100

재직자 평가 의견

Logistic Regression에서 시작해 AdaBoost 앙상블로 성능을 93.7%까지 끌어올린 단계적인 접근 방식은 아주 훌륭한 결과물인 것 같습니다. 특히, 단순히 모델을 만드는 데 그치지 않고 ROI나 LTV 같은 비즈니스 관점까지 확장하여 기술의 실제 가치를 증명한 점이 매우 뜻깊은 경험으로 보입니다. 다만, 데이터 전처리 과정에서 이상치 처리가 누락된 점과 학습 과정에서의 데이터

누수의 가능성은 반드시 재검토해보는 것이 좋을 것 같습니다. 실무 데이터는 정제된 데이터보다 훨씬 예측 불가능한 값들이 많아 이러한 예외 케이스를 놓치면 실제 운영 단계에서 모델 신뢰도가 급격히 떨어질 수 있습니다.

또한, 코드 내에 존재하는 하드코딩이나 예외 처리 부재는 미래의 동료를 위해 조금 더 신경 써주시면 좋겠습니다. 왜 이 딥러닝 구조를 선택했는지 를 감이 아닌 데이터와 실험 결과로 명확히 제시하고, 코드를 조금만 더 단단하게 리팩토링한다면, 더 훌륭한 프로젝트가 될 것 같습니다

강사님 평가 의견

□ 평가 의견

- (의견 기재)

전반적으로 잘 만들었습니다. 몇가지 개선점이 보여 이것만 보완하면 좋을 거 같습니다.

이상치 탐지 및 처리 누락, 데이터 누수 가능성, SMOTE 적용 순서 불명확, 딥러닝 구조 선택 근거 부족, 하이퍼파라미터 탐색 범위 설정 근거 미흡, CV 점수와 Test 점수 혼용, 시간 기반 검증 부재, Meta 모델 선택 근거 약함, SHAP/LIME 같은 고급 해석 기법 미사용, 실무 운영 전략 부족, 모델 공정성 검증 누락 등이 개선이 필요한 부분입니다.

특히 이상치 처리를 완전히 누락한 것과 데이터 누수 가능성의 검토가 필요해 보입니다.

또한 코드 품질 측면에서도 하드코딩, 매직 넘버, 에러 핸들링 부재, 중복 코드 등 리팩토링이 필요합니다.

코드를 보면 라이브러리가 조금 오래된거 같은데.. 아마도 종속성때문일 거라고 생각됩니다...

이 버전도 사용을 고려해 보면 좋을것 같습니다.

scikit-learn>=1.3.0,<2.0.0

xgboost>=2.0.0,<3.0.0

lightgbm>=4.0.0,<5.0.0

테이블 데이터에 CNN 사용했습니다.

CNN은 이미지/시계열에 적합, 테이블 데이터는 부적합합니다. 그래서

TabNet 또는 FT-Transformer 사용을 다음코드를 기반으로 고려해보시면 좋을거 같습니다.

```
# pip install pytorch-tabnet
```

```
from pytorch_tabnet.tab_model import TabNetClassifier
```

```
clf = TabNetClassifier(  
    n_d=64, n_a=64,  
    n_steps=5,  
    gamma=1.5,  
    n_independent=2, n_shared=2,  
    momentum=0.3  
)  
clf.fit(  
    X_train, y_train,  
    eval_set=[(X_test, y_test)],
```

Age에 One-Hot Encoding 적용했습니다. 이는 지나치게 고차원화 됩니다.
Age는 순서가 있는 수치형 변수입니다.

구간화(Binning) 사용할것을 추천드리며 사용법은 다음과 같습니다

```
from sklearn.preprocessing import KBinsDiscretizer
```

```
age_binner = KBinsDiscretizer(n_bins=5, encode='ordinal', strategy='quantile')  
df['age_group'] = age_binner.fit_transform(df[['age']])
```